




데이터 마이닝과 분석_회귀

주택 특성 기반 판매가격 예측 모델링



7조: 이정현 임규빈 임승휘 하지운



CONTENTS

1 프로젝트 개요

2 데이터 전처리

3 모델 성능 비교

4 최종 모델 분석

1 프로젝트 개요

문제 정의

1. 주택 가격은 여러 요인이 복합적으로 작용
2. 변수 간 상관·비선형 구조가 존재하여 단순 모델로는 설명 어려움

데이터 정보

구분	내용
데이터 크기	2,344개
변수	31개 30개 독립변수 + 1개 종속변수
분할	Train 80% / Test 20% (random_state=42)

2 데이터 전처리 - 결측치 처리

**Garage
Type · Finish · Cars**



판단 기준	처리 방식
세 변수 모두 결측 → 차고 없음(NoGarage)	NoGarage / Cars=0으로 통일
일부만 결측 → 정보 누락	동일 그룹 Mode로 대체

Bsmt 관련 변수



판단 기준	처리 방식
TotalBsmtSF = 0 → 지하실 없음	관련 변수 모두 “NoBsmt”로 통일
TotalBsmtSF > 0인데 결측	동일 그룹 Mode로 대체

FireplaceQu



판단 기준	처리 방식
Fireplace=0 → 벽난로 없음	“NoFireplace”로 통일
Fireplace>0인데 결측	Mode로 복원

2 데이터 전처리 - 결측치 처리


Lot Frontage

방법 1

Neighborhood 기준 중앙값으로 대체

방법 2

회귀 기반 예측 모델로 결측 값 추정



방법2 Lasso 기반 예측값으로 대체

2 데이터 전처리 - 이상치 처리

로그 변환

로그 변환(Log Transform) 적용 이유

1. 면적·연면적 등 오른쪽으로 긴 꼬리(Skew) 분포 존재
2. 극단값이 모델에 과도한 영향을 줌
3. 로그 변환으로 분포 안정화 + 이상치 영향 완화


로그 변환 대상 컬럼 (왜도 기준 > 1)

- lot_area
- gr_liv_area
- total_bsmt_sf
- open_porch_sf
- lot_frontage


로그 변환을 통해 분포를 안정화하여 모델의 예측 성능을 높인 단계

2 데이터 전처리 - 이상치 처리

로그 변환 그래프 결과



극단적으로 오른쪽 꼬리가 긴 분포
→ 모델이 큰 값에 과도하게 반응



분포가 완만해지고 정규성에 가까워짐
→ 극단값 영향이 완화됨

2 데이터 전처리 - 이상치 처리

IQR 처리

$$* IQR = Q3 - Q1$$

제거 규칙: $Q1 - 1.5 \times IQR$ 미만 or $Q3 + 1.5 \times IQR$ 초과

변수	제거 비율(%)	처리 결정	이유
Lot Area	4.8%	제거	대지 면적 극단값 → Log 변환했지만 남은 이상치는 제거
GR Liv Area	2.3%	제거	거주면적 극단값이 모델 학습 방해
Total Bsmt SF	2.5%	제거	Basement 면적 값이 과도하게 큰 샘플 존재
Open Porch SF	2.0%	제거	Porch 면적 극단값이 분포 왜곡
Lot Frontage	0%	제거 X → 예측 기반 대체	LotFrontage는 결측이 구조적 문제 but 제거 시 손실 큼 → Lasso 기반 예측으로 채움

2 데이터 전처리 - 범주형 인코딩

범주형 인코딩

순서가 있는 변수형

Target Encoding

- 품질 등급(qual), 구조 등급(level)처럼 등급 간 순서가 존재하는 변수에 적용
- SalePrice 평균값으로 숫자 변환
- 차원 축소 + 등급 차이를 모델이 더 잘 학습함

순서가 없는 변수형

One-Hot Encoding

- 카테고리 간 순서 의미가 없는 변수에 적용
- 독립 컬럼으로 확장해 구조/지역 차이를 그대로 유지



2 데이터 전처리 - 스케일링

스케일링 방식: RobustScaler

스케일링이 필요한 이유: 변수 간 스케일 차이가 크면 회귀 모델 계수에 왜곡 발생

데이터 특성 : Lot Area, Gr Liv Area 등 극단값이 많은 연속형 변수 존재

RobustScaler 선택 이유: Outlier 많은 데이터에서 가장 안정적인 스케일링 성능

3 모델 성능 비교 - 상관 계수 기반

상관계수(corr)

Corr 값	해석
0.00 ~ 0.10	거의 무의미 → 제거 후보
0.10 ~ 0.30	약한 영향 (weak)
0.30 ~ 0.50	중간 영향 (moderate)
0.50 ~ 0.70	강한 영향 (strong)
0.70 이상	매우 강한 영향

MI (Mutual Information)

Corr 값	해석
0.00 ~ 0.10	거의 영향 없음 → 제거 strong 후보
0.10 ~ 0.30	매우 약함
0.30 ~ 0.50	약함(weak) / 영향 작음
0.50 ~ 0.70	중간 영향 (moderate)
0.70 이상	강한 변수 (중요 Feature)

Corr & MI 두 기준을 동시에 적용해 노이즈 변수 제거 → Ridge 변수 선택 지표

3 모델링 성능 비교 - Ridge

Ridge = '완전 제거'가 아닌 가중치 기반 변수 필터링 역할

[변수 선택 과정]

- 01 Ridge α 값 튜닝(규제 강도 결정)
- 02 가중치(Coef) 절댓값 상위/하위 변수 비교
- 03 Ridge 1차 실행 → 낮은 계수 변수 제거
- 04 Ridge 2차 재학습 → 재필터링
- 05 Ridge 3차 수행 → 추가 성능 비교

[결과표]

단계	변수 수	Test RMSE	해석
Ridge 1차	67 → (Corr&MI 기준 노이즈 제거)	21,348	과적합 위험 낮아지고 기본 성능 안정화 성공
Ridge 2차	42 → (Coef 기반 추가 정제)	22,451	변수 축소 효과는 있으나 RMSE 상승 → 정보 손실 발생
Ridge 3차	68 → (재확장 비교)	20,917	1차 대비 성능 개선 없고 오히려 전체 변수 증가

3 모델 성능 비교 - Lasso

Lasso = L1 규제로 불필요 변수 자동 제거

[진행 방식]

- 01 GridSearchCV로 최적 Alpha 탐색 ($\alpha=100$ 선택)
- 02 L1 규제 적용 → Coefficient가 0이 되면 변수 자동 제거 (Feature Selection 기능)
- 03 변수 축소 후 RMSE 성능 비교 및 모델 적합성 평가

[Lasso 결과]

항목	결과
전체 Feature 수	77개
Lasso 적용 후 남은 Feature	54개 (23개 제거)
CV RMSE	24,472
Test RMSE	20,970

3 모델 성능 비교 - ElasticNet

ElasticNet = L1 + L2 규제 병합

[적용 목적]

L1 + L2 규제 동시 적용, 변수 선택과 가중치 축소를 함께 수행
과대적합 방지와 성능 확보를 균형 있게 달성하기 위한 선택

[튜닝 전략]

GridSearchCV로 α (alpha), l1_ratio 최적화

다양한 규제 강도 조합 탐색 후 교차검증 기반으로
best parameter 선정

[결과]

항목	값
하이퍼파라미터	alpha = 0.01, l1_ratio = 0.5
CV RMSE	24,415
Test RMSE	20,682

3 모델 성능 비교 - 최종 결과

RMSE 기준 최종 비교 결과

Model	CV RMSE	Test RMSE	사용 변수 수
ElasticNet	24,415	20,682	77개
Lasso	24,472	20,970	54개
Ridge 1차	24,671	21,348	67개
Ridge 2차	24,527	22,451	42개
Ridge 3차	25,978	20,917	69개

Ridge: 변수 제거 대신 가중치 축소 중심 → 완전 제거 X

Lasso: 변수 54개로 강력 축소, 핵심 Feature만 남김

ElasticNet: L1+L2 균형 → 안정성 + 변수 압축 일부 확보

Test RMSE 최적 = ElasticNet

4 최종 모델 분석

최종 모델 : ElasticNet

L1+L2 규제 결합 → 변수 선택 + 안정성 확보 (균형형 모델)
최종 하이퍼파라미터: $\alpha=0.01$, $l1_ratio=0.5$

- 1 L1+L2 규제의 장점 결합
- 2 Ridge 단독 / Lasso 단독의 한계 보완 → ElasticNet이 두 방식의 단점을 보완한 중간 해답
- 3 다양한 형태의 Feature가 많은 이번 데이터에 적합 → ElasticNet이 다중공선성 + 변수 압축 문제를 동시에 해결
- 4 Train/Test 성능 간 차이가 적음
- 5 MAPE 10% 미만 달성

4 최종 모델 분석



Train & Test Performance

Metric	Train	Test	해석
R ²	0.9041	0.9152	예측 설명력 매우 우수
Adjusted R ²	0.8991	0.8941	과적합 없이 일반화 성능 확보
MAPE	9.53%	9.28%	평균 오차 ±9% 수준 → 실사용 가능

Train과 Test의 성능이 유사 → 과적합/과소적합 위험 낮음
실험 모델 중 가장 낮은 RMSE/오차율 → 최종 선택 이유 명확

Train-Test 간 성능 차이 ≤ 0.02 → 모델 신뢰도 확보 & Generalization 우수

4 최종 모델 분석 - 산점도 분석



결론 : 모델이 학습 패턴을 테스트 데이터에 성공적으로 일반화 → 실사용 가능 수준



이상으로 발표를 마치겠습니다.

감사합니다.

